



IMAGE RESTORATION & DENOISING UN'ANALISI ABLATIVA SU ARCHITETTURE PROFONDE

CORSO DI ARTIFICIAL INTELLIGENCE AND MACHINE LEARNING.

GIUSEPPE ALTAMURA, EMANUELE VIOLI, ANGELO ALBANO.

ANNO ACCADEMICO 2025/2026

INDICE



Il Problema: Denoising e Perdita di Informazione



I Dati: FashionMNIST, CIFAR-10, CIFAR-100



Le Architetture: Dall'Autoencoder Semplice alla ResNet



Risultati: Ablation Study e Confronto Visivo



Conclusioni

IL PROBLEMA REALE: DENOISING



Le immagini digitali sono spesso corrotte (sensori, compressione, trasmissione).



Obiettivo: Recuperare il segnale originale da un input degradato.



Sfida: Il modello deve "immaginare" i dettagli mancanti basandosi sul contesto.

IL NEMICO: GAUSSIAN NOISE E

....

Tipo di rumore scelto: Gaussian (Additivo) e Salt & Pepper (Impulsivo).

- il Rumore Gaussiano è **democratico**: colpisce tutti i pixel dell'immagine.
- **Matematicamente:** Ad ogni pixel originale $I(x,y)$ viene aggiunto un valore n :

$$I_{\text{corrotto}} = I_{\text{originale}} + n$$

- **La Distribuzione:** Questo valore n , non è a caso uniforme, ma segue una Distribuzione Normale:

La media è solitamente **0**: significa che statisticamente l'immagine non diventa più chiara o più scura nel complesso.

La maggior parte dei pixel subisce solo una **piccola variazione** (valori vicini allo 0).

Pochi pixel subiscono una **grande variazione**.

- **Additivo:** perché somma matematicamente un valore di disturbo a ogni pixel dell'immagine ($I+n$), "sporcando" l'informazione senza cancellarla del tutto.

SALT & PEPPER

- Mentre nel rumore Gaussiano l'informazione originale è sotto il rumore (è solo alterata), nel Salt & Pepper l'informazione in quel pixel è **fisicamente cancellata**.
- **Matematicamente:** è una sostituzione:

$$I(x, y) = \begin{cases} 0 \text{ (Pepe)} & \text{con probabilità } p/2 \\ 1 \text{ (Sale)} & \text{con probabilità } p/2 \\ I_{originale} & \text{con probabilità } 1 - p \end{cases}$$

In questo caso, il valore del pixel originale viene sovrascritto con il minimo (nero, il 'pepe') o il massimo (bianco, il 'sale'). Dove cade il rumore, l'informazione è persa al 100%. Non c'è modo di recuperarla filtrando.

- **Falsi Bordi:** Questo rumore crea dei contrasti fortissimi (dal nero al bianco in un solo pixel) che confondono le reti neurali, perché assomigliano a dei bordi o a dei contorni di oggetti.
- **Impulsivo:** perché colpisce come un impulso improvviso e isolato, sostituendo brutalmente il valore originale del pixel con un estremo (0 o 1) e distruggendo l'informazione in quel punto.

L'ESPERIMENTO "MIX NOISE": ANALISI DI UN CASO LIMITE




Un Esperimento Estremo Abbiamo messo alla prova i modelli in uno scenario "da incubo", sovrapponendo i due rumori (Gaussiano + Salt & Pepper). Volevamo vedere se l'IA riuscisse a gestire un'immagine che fosse contemporaneamente "sgranata" e piena di "buchi", un compito molto più difficile della semplice pulizia.



Il Modello va in "Confusione": I risultati non sono stati ottimali a causa di un conflitto di obiettivi: per togliere la grana il modello deve sfocare, ma per i buchi deve essere netto. Cercando di fare entrambe le cose insieme, la rete si è bloccata in una via di mezzo, producendo immagini poco definite e "impastate".



La Decisione: "Divide et Impera" Abbiamo capito che 30 epoche erano troppo poche per risolvere un problema così complesso. Di fronte a risultati incerti, abbiamo preso una decisione strategica: separare i task. Invece di insistere sul mix, abbiamo scelto di addestrare i modelli singolarmente: prima dedicandoci solo al rumore Gaussiano, poi solo al Salt & Pepper. Questo ci ha permesso di isolare le difficoltà e valutare le vere prestazioni delle architetture.





Analisi Ablativa (Ablation Study):



- La profondità della rete aiuta sempre?



- Quanto incidono le Skip Connections?



Confronto tra apprendimento da zero vs Transfer Learning.

OBIETTIVO DELLO STUDIO


ABLATION STUDY

Un Ablation Study (studio di ablazione) consiste nel **rimuovere ("ablare") specifici componenti** di un modello complesso per capire quanto ciascuno di essi contribuisca alle prestazioni finali.

- È come un esperimento scientifico di "sottrazione":
- Ad es: Hai il tuo modello completo (Modello A).
- Crei una versione "mutilata" senza una specifica funzionalità (Modello B).
- Confronti i risultati.
- Se il Modello A funziona molto meglio del Modello B, hai dimostrato che quella funzionalità rimossa era essenziale. Se le prestazioni sono identiche, quella funzionalità forse è superflua.
- L'ablation study deve dimostrare che i blocchi residuali aggiunti migliorano la capacità di denoising rispetto ad **un** auto-encoder classico.

LA PROFONDITÀ DELLA RETE AIUTA SEMPRE?

- In teoria, siamo portati a pensare che aggiungendo più strati, quindi rendendo la rete più profonda, il modello abbia automaticamente più 'capacità mentale' per imparare caratteristiche complesse e astratte dell'immagine.
- Quindi: più profondo = migliore. Tuttavia quando proviamo ad impilare troppi layer uno sopra l'altro in un Auto-Encoder standard, le prestazioni non migliorano, anzi, spesso peggiorano drasticamente, e non stiamo parlando solo di overfitting.



- Il colpevole ha un nome preciso: si chiama **Vanishing Gradient**, o 'Problema della Scomparsa del Gradiente'.
- Durante l'addestramento, la rete deve correggere i suoi errori propagando il segnale dall'uscita fino all'ingresso (la Backpropagation). Ma in una rete molto profonda, senza 'aiuti' strutturali, questo segnale di correzione diventa sempre più debole man mano che torna indietro, fino a svanire del tutto.
- Risultato:
- Il risultato è che i primi strati della rete si 'spengono' e non imparano più. L'obiettivo del nostro studio, quindi, è provare che i **Blocchi Residuali** riaccendono questi strati. Grazie alle skip connections, creiamo un canale diretto per i dati, permettendo anche a una rete molto profonda di addestrarsi correttamente.

LA SOLUZIONE: RESIDUAL BLOCKS (SKIP CONNECTIONS)

Come facciamo a sfruttare la potenza della profondità senza bloccare l'apprendimento?



I blocchi residuali: In un blocco normale, l'input passa attraverso i filtri e ne esce trasformato. Nel blocco residuale, invece, aggiungiamo la **Skip Connection**. Questa connessione prende l'informazione in ingresso e la 'trasporta' direttamente all'uscita, sommandola al risultato delle convoluzioni.

LA SOLUZIONE: RESIDUAL BLOCKS (SKIP CONNECTIONS)

Importante per il denoising, perché:




È un'autostrada per il gradiente: Se la rete è troppo profonda e il segnale rischia di perdersi, questa connessione agisce come un 'ponte', permettendo al segnale di scorrere liberamente avanti e indietro.



Protezione dei Dettagli: Nel denoising, il rischio è che pulendo l'immagine si cancellino anche i bordi e i dettagli fini. La skip connection garantisce che la struttura originale dell'immagine venga preservata e non lavata via insieme al rumore.

PIPELINE DEL PROGETTO



- Il processo inizia con l'Immagine pulita. A differenza dei metodi classici, noi non diamo questa immagine direttamente alla rete. Prima, la passiamo attraverso un blocco di corruzione, dove iniettiamo artificialmente il rumore (Gaussiano o Salt & Pepper). In questo modo, ogni volta che la rete analizza un'immagine, il rumore introdotto è leggermente diverso. Ciò evita che il modello memorizzi i dati e favorisce invece una migliore capacità di generalizzazione.
- L'immagine corrotta entra quindi nel **Modello AI**, che tenta di ripulirla e produce l'**Output Ricostruito**.
- Ma l'aspetto più critico è: il calcolo della **Loss**, ovvero dell'errore. Non abbiamo confrontato il risultato della rete con l'immagine rumorosa che ha ricevuto in ingresso. Confrontiamo il risultato direttamente con l'Immagine Originale Pulita.
- In questo modo, stiamo di fatto dicendo alla rete di ignorare il rumore in ingresso e di ricostruire l'immagine originale. È proprio questo meccanismo che trasforma un Auto-Encoder in un Denoising Auto-Encoder.

I DATASET SCELTI

ABBIAMO SELEZIONATO 3 DATASET
PER TESTARE LA
GENERALIZZAZIONE (DAL B/N
SEMPLICE AI COLORI COMPLESSI)

1. FASHION-MNIST: GRAYSCALE,
FORME GEOMETRICHE.

2. CIFAR-10: RGB, OGGETTI
NATURALI.


3. CIFAR-100: RGB, ALTA VARIABILITÀ.

PREPROCESSING & RESIZE

- Una volta selezionati i dataset, ci siamo scontrati subito con un problema pratico: i dati non nascono tutti uguali. Infatti, FashionMNIST ha immagini native di 28x28 pixel, mentre i dataset CIFAR sono a 32x32.
- Il primo passo del preprocessing è stato uniformare tutto a **32x32 pixel**. Questa scelta è matematica: 32 è una potenza di 2 (2^5), il che permette alla nostra architettura Encoder-Decoder di dimezzare l'immagine più volte senza mai generare dimensioni dispari o errori di arrotondamento.
- Infine, abbiamo applicato la normalizzazione: invece di dare in pasto alla rete i valori grezzi dei pixel (da 0 a 255), li abbiamo 'schiacciati' in un intervallo tra 0 e 1, poiché le reti neurali lavorano con pesi molto piccoli, così mettiamo il modello nelle condizioni ideali per imparare velocemente.

L'ARCHITETTURA PROPOSTA: RESIDUAL AUTO-ENCODER

- **Residual Auto-Encoder** è l'architettura che abbiamo progettato. Abbiamo mantenuto la classica struttura a clessidra tipica degli Auto-Encoder:
- A sinistra c'è l'**Encoder**, che agisce come un imbuto: comprime l'immagine per estrarne le caratteristiche essenziali e scartare le informazioni superflue.
- A destra c'è il **Decoder**, che fa l'opposto: prende queste caratteristiche compresse e tenta di ridisegnare l'immagine originale pulita.
- Il passaggio più significativo, tuttavia, avviene nella parte centrale della rete, nel cosiddetto **Collo di Bottiglia (Bottleneck)**. Mentre un modello base qui avrebbe solo pochi neuroni, noi abbiamo inserito una sequenza di **Blocchi Residuali**. Grazie alle skip connections, questa parte centrale può essere molto profonda ed elaborare i dati in modo complesso senza perdere informazioni e senza bloccare l'apprendimento.
- In sintesi: l'Encoder 'capisce' l'immagine, i Blocchi Residuali separano il contenuto dal rumore, e il Decoder ricostruisce il risultato finale.




TRAINING VS TEST SET

Per garantire la validità scientifica dei dati, abbiamo applicato una separazione del dataset.


- Una parte dei dati, il **Training Set**, è stata usata dalla rete per imparare e aggiornare i propri parametri interni.
- L'altra parte, il **Test Set**, è stata tenuta completamente nascosta al modello durante l'intera fase di addestramento.

Le immagini ricostruite provengono esclusivamente dal Test Set. In questo modo, stiamo misurando la reale capacità della rete di generalizzare, ovvero di rimuovere il rumore da immagini che non ha mai incontrato prima, dimostrando che ha imparato la logica della ricostruzione e non ha semplicemente memorizzato gli esempi.

VISUALIZZAZIONE DATASET RUMOROSO



Gaussian Noise



Salt & Pepper Noise

PANORAMICA DEI MODELLI

1. SimpleAE: Autoencoder di base (Shallow).

2. DeepNoSkip: Rete profonda lineare.

3. DeepSkip: Rete profonda con Residual Blocks.

4. TransferResNet: ResNet18 pre-addestrata + Decoder.

MODELLO 1: SIMPLEAE (BASELINE)

Il **SimpleAE** è un Auto-Encoder classico con un'architettura 'Shallow', cioè poco profonda: è composto da soli due strati di convoluzione per comprimere l'immagine (Encoder) e due strati per ricostruirla (Decoder).


I Vantaggi:

- **Velocità ed Efficienza:** Avendo pochissimi parametri, l'addestramento è estremamente rapido e richiede risorse computazionali minime.
- **Riferimento Scientifico:** Ci serve come 'Sanity Check'. Se i nostri modelli più complessi non riescono a superare le prestazioni di questa rete elementare, sapremo subito che c'è un errore nella nostra progettazione.

Gli Svantaggi:

- **Capacità Limitata:** A causa della sua scarsa profondità, la rete non ha abbastanza 'memoria' per imparare feature complesse o texture dettagliate.
- **Output Sfocato:** Per abbassare l'errore matematico, il modello tende a fare una semplice media dei pixel, restituendo immagini ripulite dal rumore ma spesso prive di nitidezza e dettagli fini.

Modello 1 - SimpleAE (La Baseline)




MODELLO 2: DEEPNOSKIP (L'INGANNO)

Il modello **DeepNoSkip** nasce come un'espansione diretta dell'approccio precedente, aumentando significativamente il numero di strati convoluzionali e di parametri addestrabili in una struttura puramente sequenziale.

L'ipotesi di partenza si basava sull'assunto classico che una maggiore profondità ("**Deeper is Better**") avrebbe permesso alla rete di apprendere feature più astratte e complesse. Tuttavia, la realtà sperimentale ha dimostrato che, senza "scorciatoie" per il flusso delle informazioni, la profondità diventa un ostacolo.

Il segnale di input subisce una degradazione eccessiva attraversando il "**collo di bottiglia**" centrale (un effetto simile al "telefono senza fili"), perdendo i dettagli fini necessari per una ricostruzione nitida. Inoltre, la retro-propagazione dell'errore è ostacolata dal **Vanishing Gradient**, rendendo l'addestramento dei primi strati inefficace e portando spesso a performance inferiori rispetto a modelli più semplici.

Modello 2 - DeepNoSkip: L'Illusione della Profondità




TEORIA: IL PROBLEMA DELLA PROFONDITÀ

Contrariamente all'intuizione comune secondo cui una maggiore profondità architettonica garantisce migliori capacità di astrazione, l'evidenza sperimentale dimostra il **paradosso della degradazione**:

l'aggiunta di strati in una rete sequenziale (Plain Net) porta a un aumento dell'errore di addestramento, saturando le performance del modello. È fondamentale distinguere questo fenomeno dall'**Overfitting**; non si tratta infatti di una memorizzazione eccessiva dei dati, ma di una difficoltà di ottimizzazione intrinseca causata dal problema del **Vanishing Gradient**.

Durante la fase di retro-propagazione, il segnale di errore deve attraversare numerose moltiplicazioni derivanti dalla Regola della Catena (Chain Rule); in una struttura molto profonda, questo gradiente decade esponenzialmente fino ad annullarsi prima di raggiungere i primi strati. Di conseguenza, la rete diviene incapace di aggiornare i pesi iniziali e fatica ad apprendere persino la funzione identità, rendendo gli strati aggiuntivi non solo superflui, ma dannosi per la corretta propagazione dell'informazione originale.



LA SOLUZIONE: RESIDUAL LEARNING


Il Cuore Matematico

- **Formula:**

$$H(x) = F(x) + x$$

- **Dove:**

- x : L'input originale (es. l'immagine rumorosa).
- $F(x)$: La "trasformazione" (o residuo) appresa dai layer convoluzionali.
- $H(x)$: L'output finale del blocco.



Perché Funziona?


- **Gradient Superhighway:** La connessione diretta crea un'autostrada per il gradiente durante la *Backpropagation*. Il segnale di errore scorre indisturbato dall'output all'input, risolvendo il problema del *Vanishing Gradient*.
- **Apprendimento Semplificato:** La rete non deve imparare l'intera immagine da zero, ma solo il "Residuo" (la differenza).
 - *Nel nostro caso (Denoising):* La rete impara a isolare il rumore ($F(x)$) per sottrarlo, lasciando passare l'immagine pulita (x).

MODELLO 3: DEEPSKIP (L'EROE)

L'implementazione del modello DeepSkip segna il passaggio dalla teoria del Residual Learning alla sua applicazione pratica in un contesto di Denoising Autoencoder.

Per mitigare il problema della degradazione, la struttura sequenziale del modello precedente è stata radicalmente modificata sostituendo i layer convoluzionali standard con **Blocchi Residui**.

A livello di codice, questo intervento introduce una connessione di identità all'interno di ogni modulo dell'Encoder e del Decoder: l'input x viene sommato all'output della trasformazione $F(x)$ prima dell'attivazione finale, permettendo al segnale di bypassare le non-linearità quando necessario. Questa architettura preserva la simmetria compressione-ricostruzione ma crea un'autostrada per il gradiente (Gradient Superhighway), garantendo che le feature spaziali ad alta frequenza, essenziali per la nitidezza dell'immagine, non vengano disperse durante la propagazione profonda.




MODELLO 4: TRANSFER LEARNING

Il Concetto (Transfer Learning)

- **Definizione:** Tecnica che consiste nel prendere un modello già addestrato su un compito massiccio (Source Domain) e riutilizzarlo come punto di partenza per un nuovo compito specifico (Target Domain).
- **Vantaggio:** Si parte da pesi già "intelligenti", non casuali.

Il Motore (ResNet18 + ImageNet)


- **La Fonte (ImageNet):** Un dataset di 1.2 milioni di immagini classificate.
- **Il Modello (ResNet18):** Una rete residuale a 18 strati che ha già imparato a riconoscere bordi, texture, forme complesse e pattern geometrici.
- **L'Applicazione:** Usiamo la ResNet18 pre-addestrata come **Encoder**.
 - *Perché?* Perché sa già "cos'è un'immagine". Deve solo imparare a distinguere il "rumore" dal "segnale", un compito molto più facile se si hanno già le basi.



ADATTAMENTO TECNICO (PARTE 1)

Il Disallineamento Dimensionale


- **Il Conflitto:**
 - **ResNet18 (Pre-trained):** Nasce per ImageNet. Si aspetta 3 canali colore (RGB: Rosso, Verde, Blu).
 - **Il Nostro Dato (FashionMNIST):** Immagini in scala di grigi. Ha solo 1 canale di profondità.
- **Perché è un problema:** Non possiamo inserire un blocco $1 \times 32 \times 32$ in una fessura sagomata per $3 \times 224 \times 224$. La matrice non combacia



La Soluzione (Fusione dei Pesi)

- **Strategia: Condensazione della Conoscenza**
 - Invece di addestrare il primo strato da zero (perdendo i vantaggi del Transfer Learning), modifichiamo i filtri esistenti.
 - **Operazione Matematica:** Calcoliamo la **media aritmetica** dei pesi dei 3 canali originali (R, G, B) e li "collassiamo" in un unico canale.
- **Risultato:**
 - Il modello mantiene la capacità di rilevare bordi e forme (appresa su ImageNet) ma ora "vede" in bianco e nero.
 - Non c'è spreco di informazioni: l'intelligenza dei tre canali viene fusa in uno solo.

ADATTAMENTO TECNICO (PARTE 2)



La "Lobotomia" (Encoder)

- **ResNet Originale:** È un *Classificatore*. La sua parte finale (Head) serve a dire "Questo è un gatto". Schiaccia tutto in un vettore di probabilità.
- **L'Intervento:**
 - **Rimozione della Testa:** Tagliamo via gli ultimi strati (Fully Connected e Average Pooling).
 - **ResNet come Backbone:** Ciò che resta agisce come un potentissimo **Encoder**. Estrae le caratteristiche (feature maps) ma non prende decisioni.

Il Trapianto (Decoder Custom)

- **Il Nuovo Obiettivo:** Vogliamo un'immagine in uscita, non una etichetta.
- **La Protesi (Decoder):**
 - Costruiamo da zero una serie di strati che fanno l'opposto della ResNet.
 - **Upsampling:** Usiamo "Transposed Convolutions" per allargare progressivamente l'immagine (da piccola e profonda a grande e sottile).
 - **Ricostruzione:** Il Decoder prende le feature estratte dalla ResNet e le "dipinge" di nuovo sulla tela 32x32.

SETUP DELL' ADDESTRAMENTO




EPOCHE: 30



OPTIMIZER: ADAM
(LR=0.001)



LOSS FUNCTION:
MSE (MEAN
SQUARED ERROR)



HARDWARE: T4
GPU (GOOGLE
COLAB)



SETUP:



Durata (Epoche): 30 (Fisse)

- **Impostazione:** EPOCHE = 30 per tutti i modelli.
- **Motivazione:** Abbiamo stabilito un "orizzonte temporale" fisso per garantire un **confronto equo (Fair Comparison)**.
- Ogni modello (dal più semplice al Transfer Learning) ha a disposizione lo stesso numero di iterazioni per convergere. Questo ci permette di valutare non solo *quanto* imparano, ma *quanto velocemente* lo fanno.

Optimizer: Adam

- **Algoritmo:** Adaptive Moment Estimation.
- **Learning Rate:** Standard (0.001).
- **Motivazione:** Scelto per la sua capacità di adattare il passo di apprendimento automaticamente, essenziale quando si confrontano architetture diverse (CNN semplici vs ResNet complesse) che potrebbero richiedere dinamiche di aggiornamento differenti.

Funzione di Costo: MSE (Mean Squared Error)

- **Metrica:** $\mathcal{L} = \frac{1}{N} \sum (y - \hat{y})^2$

dove N è il numero totale di pixel, y è il valore del pixel nell'immagine originale, mentre $\hat{y}$ è il valore del pixel nell'immagine ricostruita.

- **Obiettivo:** Minimizzare la differenza pixel-per-pixel tra l'immagine originale e quella ricostruita.
- **Perché:** È la metrica standard per problemi di regressione e restauro immagini, poiché penalizza fortemente gli errori visivi grossolani.

Hardware: NVIDIA T4 (Google Colab)


- **Accelerazione:** GPU dedicata con 16GB VRAM.
- **Necessità:** Indispensabile per gestire il carico computazionale della **ResNet18** (milioni di parametri) e l'elaborazione parallela dei batch.

I Dataset - Una sfida crescente

Abbiamo scelto tre dataset per testare la robustezza dei modelli a diversi livelli di complessità.

Nome Dataset	Tipo Immagine	N° Classi	Complessità	La Sfida Principale
Fashion-MNIST	Grayscale	10	Bassa	Forme geometriche semplici, texture dei tessuti.
CIFAR-10	Colori (RGB)	10	Media	Immagini naturali, variazioni di luce, sfondi complessi.
CIFAR-100	Colori (RGB)	100	Alta	Scarsità di dati per classe. Test di generalizzazione estremo.

Nota: Tutte le immagini sono piccole (28x28 o 32x32), rendendo la perdita di dettagli spaziali un rischio critico.



La Nostra "Scuderia" di Modelli

Abbiamo progettato quattro architetture distinte per isolare e analizzare l'impatto di specifiche componenti architettoniche (profondità, skip connections, pre-training).



SimpleAE:

Il riferimento di base
(Baseline leggera).



DeepNoSkip:

Per testare se "più profondo
è meglio".



DeepSkip (Ours):

L'architettura proposta (U-
Net like).




TransferResNet:

Il gigante pre-addestrato
(Transfer Learning).

Oltre la Loss - Le Metriche di Valutazione

- **Perché la Loss non basta:** L'MSE è un calcolo matematico utile per l'addestramento, ma non riflette la qualità percepita dall'occhio umano. Un'immagine sfocata può avere un buon MSE.
- Il **PNSR** (Peak Signal-to-Noise Ratio), ovvero “Rapporto Segnale-Rumore di Picco”
- **La Metrica Regina: SSIM (Structural Similarity Index)**
 - Misura la similarità strutturale (luminanza, contrasto, struttura) tra due immagini.
 - Range: da 0 (diverso) a 1 (identico).
 - È il nostro standard di riferimento per la qualità visiva.




Risultati Quantitativi Gaussian- La Pagella Finale

Tabella riassuntiva dei valori medi sui Test Set. **DeepSkip** mostra la performance più alta e stabile.

Modello	Metrica	Fashion-MNIST	CIFAR-10	CIFAR-100
SimpleAE	MSE (↓)	0.0018	0.0022	0.0024
	PSNR (↑)	27.38 dB	26.59 dB	26.14 dB
	SSIM (↑)	0.92	0.84	0.83
DeepNoSkip	MSE (↓)	0.0016	0.0026	0.0027
	PSNR (↑)	28.10 dB	25.90 dB	25.70 dB
	SSIM (↑)	0.94	0.85	0.83
DeepSkip (Ours)	MSE (↓)	0.0011	0.0016	0.0017
	PSNR (↑)	29.62 dB	27.87 dB	27.74 dB
	SSIM (↑)	0.96	0.89	0.89
ResNet18 (Transfer)	MSE (↓)	0.0037	0.0075	0.0082
	PSNR (↑)	24.34 dB	21.26 dB	20.88 dB
	SSIM (↑)	0.89	0.64	0.62

↑: High is better
↓: Low is better

Highlight: Notare il crollo verticale di ResNet18 passando ai dataset a colori.




Risultati Quantitativi Salt&Pepper - La Pagella Finale

Tabella riassuntiva dei valori medi sui Test Set. **DeepSkip** mostra la performance più alta e stabile.

Modello	Metrica	Fashion-MNIST	CIFAR-10	CIFAR-100
SimpleAE	MSE (↓)	0.00133	0.00398	0.00433
	PSNR (↑)	28.77 dB	24.00 dB	23.64 dB
	SSIM (↑)	0.95	0.77	0.76
DeepNoSkip	MSE (↓)	0.00089	0.00200	0.00208
	PSNR (↑)	30.52 dB	27.00 dB	26.82 dB
	SSIM (↑)	0.97	0.89	0.88
DeepSkip (Ours)	MSE (↓)	0.00018	0.00049	0.00061
	PSNR (↑)	37.56 dB	33.13 dB	32.13 dB
	SSIM (↑)	0.99	0.97	0.97
TransferResNet	MSE (↓)	0.00414	0.00793	0.00872
	PSNR (↑)	23.86 dB	21.01 dB	20.61 dB
	SSIM (↑)	0.88	0.63	0.61


↑: High is better
↓: Low is better

Highlight: Notare il crollo verticale di ResNet18 passando ai dataset a colori.




Risultati Visivi rumore Gaussiano FashionMNIST


Risultati: SimpleAE
Originale




Risultati: DeepNoSkip
Originale







Risultati: DeepSkip
Originale



Risultati: TransferResNet
Originale




Risultati Visivi rumore Gaussiano CIFAR10



Risultati Visivi rumore Gaussiano CIFAR 100

Risultati: SimpleAE
Originale




Risultati: DeepNoSkip
Originale







Risultati: DeepSkip
Originale







Risultati: TransferResNet
Originale







Risultati Visivi rumore Salt&Pepper FashionMNIST



Risultati Visivi rumore Salt&Pepper CIFAR10




Risultati Visivi rumore Salt&Pepper CIFAR100




Analisi 1 - Il Paradosso della Profondità

- **Domanda:** Aumentare la profondità senza Skip Connections aiuta sempre?
- **Dati (CIFAR-10):**
 - **SimpleAE (Superficiale):** MSE 0.0022 | SSIM 0.84
 - **DeepNoSkip (Profondo):** MSE 0.0026 | SSIM 0.85
- **Osservazione:** Su dati a colori complessi, il modello più profondo ha faticato di più a convergere (MSE peggiore) rispetto a quello semplice, ottenendo un guadagno di SSIM trascurabile.
- **Conclusione:** Senza "ponti", la profondità diventa un ostacolo a causa del *Vanishing Gradient*. La rete non riesce a ottimizzare efficacemente i layer iniziali.




Analisi 2 - Il Potere delle Skip Connections

- **Confronto Visivo: DeepNoSkip vs DeepSkip**
- **DeepNoSkip:** Produce immagini con colori "slavati" (desaturati) e bordi poco definiti. L'informazione del colore si perde nel bottleneck.
- **DeepSkip:** Colori vividi e fedeli all'originale. Bordi netti. Le Skip Connections hanno permesso ai canali RGB originali di bypassare la compressione e arrivare al decoder.
- **Verdetto:** Per il restauro di immagini, le U-Net (DeepSkip) sono superiori agli Autoencoder classici.



Analisi 3 - Il Fallimento del Transfer Learning

- **Il Caso ResNet18:** Perché ha ottenuto i risultati peggiori (SSIM 0.62 su CIFAR-100) nonostante fosse la più "intelligente"?
- **Diagnosi Tecnica:**
 - ResNet è progettata per *classificare* immagini grandi (224x224).
 - Utilizza operazioni di *Pooling* aggressive che riducono la dimensione spaziale per estrarre concetti astratti (es. "c'è un gatto").
 - Su immagini piccole (32x32), questo pooling distrugge quasi tutta l'informazione spaziale (dove si trova il pixel?).
- **Conclusione:** Il decoder non può ricostruire ciò che l'encoder ha distrutto. Le architetture di classificazione non sono ottimali per la ricostruzione a bassa risoluzione.



Trade-off: Velocità vs Qualità

Non esiste un modello perfetto. Dobbiamo bilanciare la qualità del risultato con il costo computazionale.



Ideale: DeepSkip.

Offre la massima qualità (SSIM 0.89+) con tempi di training gestibili.




Veloce ma impreciso: SimpleAE.

Ideale per dispositivi a basse risorse, ma la qualità è inferiore.




Lento e... scarso: ResNet18.



In questo specifico task, è stata la più lenta ad addestrare e la peggiore come risultati. Inefficiente.



Interpretabilità - Cosa vede la rete? (Grad-CAM)


- **Aprire la "Black Box":** Non ci accontentiamo dei numeri. Vogliamo capire *come* la rete lavora.
- **La Tecnica:** Abbiamo adattato l'algoritmo Grad-CAM per visualizzare delle "Heatmaps" (mappe di calore). Queste ci mostrano su quali aree dell'immagine la rete si sta concentrando maggiormente per minimizzare l'errore di ricostruzione.





Heatmaps in Azione

- **Osservazione Visiva:**
 - Le immagini mostrano che l'attivazione massima (colore rosso) non è casuale o sullo sfondo.
 - La rete si concentra selettivamente sui **bordi ad alto contrasto** e sui contorni degli oggetti.
- **Interpretazione:** La rete ha imparato autonomamente che il rumore Salt & Pepper distrugge la struttura. Per "riparare" l'immagine, dedica le sue risorse a ricostruire la geometria essenziale dell'oggetto, ignorando le aree uniformi.



Conclusioni e Lezioni Apprese

1 L'Architettura Conta Più della Taglia:

Una rete custom ben progettata (DeepSkip U-Net) batte un gigante industriale mal adattato (ResNet) per il task di denoising a bassa risoluzione.

2 Skip Connections Sono Essenziali:



Sono l'elemento architettonico che fa la differenza tra un'immagine sfocata e una nitida, risolvendo il problema del vanishing gradient e del recupero dei dettagli.

3 Attenzione alle Metriche:

L'MSE da solo può ingannare. L'analisi visiva e metriche percettive come l'SSIM sono indispensabili.

4 Transfer Learning Non è Magia:

Deve essere applicato con giudizio. Se il task target (ricostruzione pixel) è opposto al task sorgente (classificazione astratta), può essere controproducente.



Grazie per l'attenzione !

